

Deep Learning aplicado em previsão de falhas em turbinas de aeronaves e equipamentos industriais

Gabriel Vinicius Boin Freitas¹

¹Centro de Ciências Tecnológicas – Universidade Estadual de Santa Catarina (UDESC)
Rua Paulo Malschitzki, 200 Zona Industrial Norte, CEP: 89.219-710 – Joinville – SC – Brazil

gvb.freitas@edu.udesc.br

Abstract. *Key words: RUL: Remaining Useful Life - Deep Learning - Turbine - Anomaly detection - Predictive maintenance - Autoencoder - Transformer*

Resumo.

1. Introdução

Nos últimos anos, o uso de técnicas de aprendizado profundo (deep learning) tem crescido significativamente em várias áreas, incluindo a indústria aeronáutica e a indústria de petróleo. Uma aplicação promissora dessa tecnologia é a previsão de falhas em turbinas de aeronaves e em grandes equipamentos industriais, como turbinas de termelétricas, grandes bombas e outros equipamentos utilizados na indústria do petróleo. [Fentaye et al. 2021, Dai et al. 2024]

O problema da previsão de falhas em turbinas de aeronaves e em grandes equipamentos industriais é de grande importância devido aos altos custos associados à manutenção corretiva e ao tempo de inatividade dos equipamentos. Além disso, a detecção precoce de falhas pode ajudar a evitar acidentes graves, reduzir os custos de manutenção e melhorar a eficiência operacional. [Fentaye et al. 2021]

Uma turbina aeronáutica é um tipo de motor a jato que converte a energia cinética do ar em movimento em energia mecânica rotacional. O processo começa com a entrada de ar na turbina, onde é comprimido em alta pressão por uma série de estágios de compressão. Em seguida, o ar comprimido é misturado com combustível e queimado em uma câmara de combustão, gerando uma rápida expansão dos gases quentes. Esses gases de alta temperatura são então expelidos por uma série de turbinas rotativas, que estão ligadas a um eixo central. A energia cinética resultante do fluxo de gases em alta velocidade através das turbinas é convertida em energia mecânica, que pode ser usada para movimentar hélices ou gerar eletricidade em um avião.

O funcionamento de turbinas utilizadas em termelétricas é essencialmente o mesmo que o de turbinas aeronáuticas. A diferença está no uso final da energia mecânica gerada. Em uma termelétrica, a energia mecânica rotacional do eixo da turbina é usada para girar um gerador elétrico, convertendo-a em eletricidade que pode ser distribuída para a rede elétrica.

As termelétricas são de interesse da indústria do petróleo porque muitas vezes são alimentadas por combustíveis fósseis, como petróleo e gás natural. Além disso, a eletricidade gerada por termelétricas é frequentemente usada em processos de extração, refino e transporte de petróleo, bem como em instalações de produção offshore, onde a

energia elétrica é necessária para operar equipamentos de perfuração, bombeamento e tratamento de água.

Os principais modos de falha em turbinas aeronáuticas são erosão, fadiga do material, fissuras, desgaste dos rolamentos, corrosão, desbalanceamento, vazamento de óleo, problemas de vedação, degradação do revestimento térmico. [Dai et al. 2024]

O objetivo geral deste trabalho é desenvolver e avaliar modelos de aprendizado profundo para prever falhas em turbinas de aeronaves e em grandes equipamentos industriais com alta precisão e antecedência. Para alcançar esse objetivo, objetivos específicos serão abordados, sendo coletar e pré-processar dados de sensores de turbinas de aeronaves, utilizando a base de dados da NASA disponível no "Prognostics Center of Excellence Data Repository", utilizar modelos de autoencoder para identificar padrões de assinatura de bom funcionamento nos dados e detectar anomalias que possam indicar falhas iminentes nos equipamentos, aplicar modelos de previsão de séries temporais, como particle filter, para prever o remaining useful life (RUL) dos equipamentos, treinar e otimizar os modelos desenvolvidos usando conjuntos de dados históricos utilizando a base de dados da NASA disponível no "Prognostics Center of Excellence Data Repository" e avaliar o desempenho dos modelos em termos de precisão, recall e F1-score, bem como compará-los com métodos tradicionais de previsão de falhas.

A metodologia de pesquisa adotada neste estudo incluirá uma revisão abrangente da literatura sobre previsão de falhas em turbinas de aeronaves e em grandes equipamentos industriais, aquisição e pré-processamento de dados utilizando a base da NASA, desenvolvimento e treinamento de modelos de aprendizado profundo, e avaliação do desempenho dos modelos. Espera-se que os resultados deste estudo contribuam significativamente para o avanço da segurança e eficiência operacional na indústria aeronáutica e na indústria de petróleo.

2. Revisão de conceitos e trabalhos relacionados

A previsão da vida útil remanescente (RUL) é uma área crítica para a manutenção preditiva e redução de custos operacionais. Diversos estudos recentes têm explorado técnicas avançadas de aprendizado profundo para melhorar a precisão dessas previsões. Ragab et al. (2020) introduziram o modelo ATS2S, que utiliza técnicas de sequência para sequência com um mecanismo de atenção, otimizando simultaneamente a perda de reconstrução e a perda de previsão de RUL [Ragab et al. 2020]. Este modelo foi destacado por sua eficácia em superar 13 métodos estado-da-arte em quatro conjuntos de dados reais, particularmente em cenários complexos com múltiplas condições operacionais. Soni et al. (2020) exploraram o uso de redes neurais convolutivas (CNN) para prever a RUL, comparando com abordagens baseadas em Long Short-Term Memory (LSTM). Os resultados indicaram que o modelo CNN proposto alcançou uma precisão de 91,74% a 94,16% em testes experimentais, superando as abordagens baseadas em LSTM [Soni et al. 2020].

Outro estudo notável é o de Wang et al. (2020a), que utilizou pares de redes adversárias para facilitar o treinamento de redes neurais, com a estabilidade assegurada por um algoritmo de amostragem baseado em RMSprop. Este método demonstrou uma melhoria significativa na previsão de RUL em comparação com métodos existentes de fusão de dados [Wang et al. 2020a]. Em termos de revisões e análises, Namuduri et al. (2020) revisaram os algoritmos de aprendizado profundo usados para manutenção preditiva,

destacando a importância dos sensores eletroquímicos e ópticos para monitoramento industrial [Namuduri et al. 2020]. Wang et al. (2020b) discutiram como técnicas de aprendizado profundo, como Autoencoders, DBN, CNN e RNN, oferecem soluções poderosas para a previsão de RUL, superando os desafios associados aos modelos baseados em física [Wang et al. 2020b]. Pang et al. (2021) realizaram uma análise detalhada das técnicas de deep learning para detecção de anomalias, destacando seu potencial para melhorar a precisão na identificação de anomalias em dados complexos [Pang et al. 2021].

Além desses modelos, Al-Khazraji et al. (2022) desenvolveram um modelo híbrido de Autoencoder e Redes de Crença Profunda (DBN) para a previsão de RUL de motores de aeronaves. Este modelo se destacou por sua capacidade de extrair características abstratas dos dados de entrada e prever a série temporal da RUL, demonstrando superioridade em comparação com outras abordagens de aprendizado profundo [Al-Khazraji et al. 2022]. Li et al. (2022) propuseram um modelo que combina CNN, LSTM e o módulo de atenção de bloco convolucional (CBAM) para prever a RUL de motores de aeronaves, alcançando uma redução de 17,4% no RMSE e uma melhoria de 25,9% no score em comparação a outros métodos estado-da-arte [Li et al. 2022]. Hu et al. (2023) apresentaram modelos de fusão baseados em Transformer que integram redes LSTM e CNN para melhorar a precisão da previsão de RUL de motores aeroespaciais, resultando em uma melhoria de até 66,53% em RMSE e 84,86% nas métricas de pontuação [Hu et al. 2023].

Finalmente, Khalaf e Ali (2023) exploraram a influência de estratégias de manutenção na performance e eficiência das turbinas a gás, enfatizando a importância da manutenção baseada no estado para melhorar a confiabilidade e reduzir os custos do ciclo de vida [Khalaf and Ali 2023].

3. Desenvolvimento da proposta de solução

A previsão da Vida Útil Restante (RUL) é uma tarefa essencial para a manutenção preditiva de motores de aeronaves. Este estudo utiliza uma abordagem híbrida que combina redes convolucionais (CNN), redes neurais recorrentes (LSTM) e camadas Transformer para prever o RUL com base em dados multivariados de sensores. A combinação dessas técnicas visa capturar tanto as características locais quanto as dependências temporais de longo prazo nos dados.

Os dados utilizados são provenientes do Conjunto de Dados de Prognósticos de Motores a Jato (C-MAPSS) fornecido pela NASA. Este conjunto de dados contém múltiplas séries temporais multivariadas divididas em quatro subconjuntos: FD001, FD002, FD003 e FD004, cada um com diferentes condições operacionais e modos de falha. Cada série temporal representa o ciclo operacional de um motor, registrando 26 variáveis em cada ciclo, incluindo configurações operacionais e medições de sensores. No subconjunto FD001, há 100 trajetórias de treino e 100 de teste, sob uma única condição operacional e um modo de falha. O subconjunto FD002 possui 260 trajetórias de treino e 259 de teste, sob seis condições operacionais e um modo de falha. O FD003 inclui 100 trajetórias de treino e 100 de teste, sob uma única condição operacional e dois modos de falha. Finalmente, o FD004 contém 248 trajetórias de treino e 249 de teste, sob seis condições operacionais e dois modos de falha.

Cada motor começa sua operação em condições normais e desenvolve uma falha

durante a série temporal. No conjunto de treinamento, a falha progride até a falha total do sistema, enquanto no conjunto de teste, a série temporal termina algum tempo antes da falha total. O objetivo é prever o número de ciclos operacionais restantes antes da falha total no conjunto de teste.

Os dados são carregados e pré-processados utilizando a biblioteca `pandas`. Durante o carregamento, colunas completamente vazias são removidas. Os dados são então normalizados usando `MinMaxScaler` para escalar as medições dos sensores entre 0 e 1. Os dados de treinamento são preparados em sequências de comprimento fixo, definidas como 200 ciclos neste estudo, para capturar a dinâmica temporal dos sensores. Cada sequência é emparelhada com o RUL correspondente, calculado como o número de ciclos restantes até a falha. Os dados de teste são preparados de forma semelhante, com preenchimento (padding) para sequências menores que o comprimento fixo.

O modelo híbrido proposto é composto por uma combinação de camadas CNN, LSTM e Transformer. Primeiramente, as camadas convolucionais (CNN) utilizam 64 filtros com tamanho de kernel 3 na primeira camada e 128 filtros na segunda camada. As camadas CNN são responsáveis por extrair características locais dos dados temporais. Em seguida, duas camadas LSTM com 100 unidades cada são usadas para capturar dependências temporais de longo prazo. A primeira camada retorna sequências, enquanto a segunda retorna a última saída. Finalmente, uma camada Transformer é utilizada para melhorar a capacidade do modelo de focar em diferentes partes da sequência de entrada. O bloco Transformer possui 100 dimensões de embedding, 2 cabeças de atenção e 64 dimensões na rede feed-forward. O modelo é compilado utilizando o otimizador `adam` e a função de perda `mean_squared_error`, devido à sua eficácia em problemas de regressão.

O modelo é treinado utilizando `early_stopping` para prevenir overfitting. O `early_stopping` monitora a perda na validação e restaura os melhores pesos após 10 épocas sem melhoria. O treinamento é realizado por 100 épocas com um tamanho de lote de 64, e uma divisão de validação de 20% dos dados de treinamento. As métricas de avaliação incluem R^2 , MAPE, MAE, MSE e RMSE, fornecendo uma visão abrangente do desempenho do modelo na previsão de RUL.

Os resultados do treinamento são visualizados através de gráficos do histórico de perda durante as épocas de treinamento. As previsões de RUL são comparadas com os valores reais utilizando scatter plots, permitindo uma análise detalhada das previsões do modelo. A combinação de CNN, LSTM e Transformer permite capturar efetivamente características locais e globais dos dados de sensores, resultando em previsões precisas de RUL. Esta abordagem híbrida demonstrou ser eficaz na tarefa de manutenção preditiva, fornecendo uma ferramenta valiosa para a gestão de motores de aeronaves.

Link para código: <https://github.com/gabrielfea/CMAPSSData>

4. Análise de Resultados e Conclusão

5. Trabalhos Futuros

References

Al-Khazraji, H., Nasser, A. R., Hasan, A. M., Al Mhdawi, A. K., Al-Raweshidy, H., and Humaidi, A. J. (2022). Aircraft engines remaining useful life prediction based on a

- hybrid model of autoencoder and deep belief network. *IEEE Access*, 10:82156–82163.
- Dai, S., Zhang, X., and Luo, M. (2024). A novel data-driven approach for predicting the performance degradation of a gas turbine. *Energies*, 17(4):781.
- Fentaye, A. D., Zaccaria, V., and Kyprianidis, K. (2021). Aircraft engine performance monitoring and diagnostics based on deep convolutional neural networks. *Machines*, 9(12):337.
- Hu, Q., Zhao, Y., and Ren, L. (2023). Novel transformer-based fusion models for aero-engine remaining useful life estimation. *IEEE Access*.
- Khalaf, K. D. and Ali, O. M. (2023). Effect of the maintenance strategy on the performance and efficiency of the gas turbine unit: A review. *Journal Européen des Systèmes Automatisés*, 56(2):259.
- Li, H., Wang, Z., and Li, Z. (2022). An enhanced cnn-lstm remaining useful life prediction model for aircraft engine with attention mechanism. *PeerJ Computer Science*, 8:e1084.
- Namuduri, S., Narayanan, B. N., Davuluru, V. S. P., Burton, L., and Bhansali, S. (2020). Deep learning methods for sensor based predictive maintenance and future perspectives for electrochemical sensors. *Journal of The Electrochemical Society*, 167(3):037552.
- Pang, G., Shen, C., Cao, L., and Hengel, A. V. D. (2021). Deep learning for anomaly detection: A review. *ACM computing surveys (CSUR)*, 54(2):1–38.
- Ragab, M., Chen, Z., Wu, M., Kwok, C.-K., Yan, R., and Li, X. (2020). Attention sequence to sequence model for machine remaining useful life prediction. *arXiv preprint arXiv:2007.09868*.
- Soni, H., Kansara, A., and Joshi, T. (2020). Predictive maintenance of gas turbine using prognosis approach. *International Research Journal of Engineering and Technology*, 7(6):4683–4691.
- Wang, F., Du, J., Zhao, Y., Tang, T., and Shi, J. (2020a). A deep learning based data fusion method for degradation modeling and prognostics. *IEEE Transactions on Reliability*, 70(2):775–789.
- Wang, Y., Zhao, Y., and Addepalli, S. (2020b). Remaining useful life prediction using deep learning approaches: A review. *Procedia manufacturing*, 49:81–88.